

UWAGA: Zadanie do wykonania punkt 12. Punkty 1–11 pokazują jak wykonać zadanie, dlatego zawierają dodatkowy obszerny opis. Państwo nie muszą aż tak obszernie objaśniać co robią: należy tylko zamieścić wyniki obliczeń + interpretacje otrzymanych wyników. W przypadku testów: postawić hipotezę, odczytać *wartość p* oraz podać wynik testy (czy odrzucamy H_0 czy nie ma podstaw).

Zadanie ma zawierać:

1. część makroekonomiczna – krótki opis znaczenia wybranej kategorii makroekonomicznej (bezrobocie, dochód narodowy, inflacja itp...) na podstawie podręczników makroekonomii max 3–4 strony [Wykonać samodzielnie]
2. wyznaczenie trendu metodą mechaniczną – średnia ruchoma [Wykonać samodzielnie]
3. ekonometryczny model tendencji rozwojowej – zastosować 2–3 postacie funkcji trendu (liniowa, kwadratowa, sprowadzana do liniowej), wg przykładu podanego w punktach 1–??.
4. wyznaczyć oraz porównać prognozy na 2–3 okresy uzyskane na podstawie:
a) trendu mechanicznego b) modelu tendencji rozwojowej (punkt 11)

Dane niezbędne do zadania oraz przykład (w postaci pliku Gretla) załączam...

1 Dane

Liczba zarejestrowanych samochodów w Polsce w latach 1998–2010 kształtowała się następująco (w sztukach):

9154934, 9343580, 9991260, 10503052, 10983654, 11243827, 11975191, 12339353, 13384229, 14588739, 16079533, 16479200, 17156400

Wykres liniowy:

widok → wykres-zmiennych → wykres szeregów czasowych

Określenie wielkości próby:

Próba → zakres próby

zmniejszamy wielkość próby o 2 obserwacja 1998–2008 (pozostałe dwie zostaną wykorzystane do oceny prognozy)

Dodawanie nowych zmiennych

Dodawanie zmiennych → definiowanie nowej zmiennej

wpisanie formuły wg schematu

nowaZmienna = wyrażenie-arytmetyczne-zawierające-zmienne, np

$x2 = x * x$

(gdzie x jest nazwą zmiennej)

2 Klasyczna metoda najmniejszych kwadratów

Szacujemy liniową funkcję trendu postaci:

$$y_t = a_0 + a_1 \cdot t + u_t$$

Na podstawie danych obejmujących lata 1998–2008 oszacowano liniowy model trendu, otrzymując następujące wyniki:

Model 2: Estymacja KMNK, wykorzystane obserwacje 1998–2008 ($N = 11$)
Zmienna zależna (Y): samochody

	współczynnik	błąd standardowy	t-Studenta	wartość p	
const	7,93812e+06	358285	22,16	3,67e-09	***
time	640424	52826,2	12,12	7,06e-07	***
Średn. aryt. zm. zależnej	11780668	Odch. stand. zm. zależnej	2188115		
Suma kwadratów reszt	2,76e+12	Błąd standardowy reszt	554046,0		
Wsp. determ. R-kwadrat	0,942298	Skorygowany R-kwadrat	0,935886		
F(1, 9)	146,9727	Wartość p dla testu F	7,06e-07		
Logarytm wiarygodności	-159,9797	Kryt. inform. Akaike’a	323,9593		
Kryt. bayes. Schwarza	324,7551	Kryt. Hannana-Quinna	323,4577		
Autokorel. reszt - rho1	0,740455	Stat. Durbina-Watsona	0,608220		

Model regresji:

$$y_t = 79381200 + 640424 \cdot t + u_t$$

Przeciętny roczny wzrost liczby samochodów w badanym okresie wynosi 640,4 tys sztuk.

3 Ocena dopasowania modelu do danych empirycznych

Na podstawie wartości skorygowanego współczynnika determinacji R^2 można stwierdzić, że model (trendu liniowego) w 93,59% objaśnia liczbę zarejestrowanych samochodów.

Albo: model (trendu liniowego) w $100\% - R^2 = 6,41$ nie wyjaśnia liczby zarejestrowanych samochodów. Współczynnik $\Phi^2 = 100\% - R^2$ nosi nazwę współczynnika zbieżności.

Błąd standardowy reszt wynosi $S_e = 554046,0$. Interpretacja: szacując liczbę zarejestrowanych samochodów na podstawie modelu trendu liniowego mylimy się średnio o plus/minus 554046 pojazdów (około 550 tys)

Współczynnik wartości resztowej $V_e = S_e/\bar{Y} \cdot 100$, gdzie \bar{Y} jest oznaczone na wydruku Gretla jako **Średn.aryt.zm.zależnej**.

Zatem: $V_e = 554046,0/11780668 \cdot 100 \approx 4,7\%$

Interpretacja: Błąd standardowy reszt stanowi zaledwie 4,7% przeciętnej wartości zmiennej objaśnianej. (Inaczej: przeciętne odchylenia wartości teoretycznych od empirycznych stanowią 4,7% wartości empirycznych.)

Model jest dobrze dopasowany.

4 Zweryfikować istotność statystyczną zmiennych

$$H_0 : a_1 = 0$$

powyższa hipoteza zerowa oznacza, że brak jest zależności pomiędzy zmienną y a czasem (t), bo jeżeli $a_1 = 0$ to $a_1 \cdot t = 0$ zatem $y = a_0$.

$$H_1 : a_1 \neq 0$$

hipoteza alternatywna jest zwykle prostym zaprzeczeniem zerowej (czasami – jeżeli dysponujemy dodatkowymi informacjami może być inaczej, np $H_1 : a_1 > 0$

Wnioskujemy o tym czy hipotezę zerową należy odrzucić czy nie **na podstawie próby**, konkretnie na podstawie wartości określonej funkcji obliczonej dla elementów z próby.

Udowodniono, że jeżeli H_0 jest prawdziwa, to funkcja $t = \hat{a}/S_a$, (\hat{a} to oszacowana wartość a) ma znany rozkład statystyczny zwany rozkładem t -Studenta. Przy czym S_a oznacza średni błąd szacunku parametru (zwany błędem standardowy na wydruku Gretla; odpowiednik odchylenia standardowego – miara określająca przeciętną wielkość błędu z jaką szacujemy parametr a), tj. w tym konkretnym przypadku 52826,2.

Zwróćmy uwagę, że w liczniku funkcji t znajduje się wartość \hat{a} , jeżeli faktycznie $\hat{a} = 0$ jak głosi H_0 , to im większa wartość \hat{a} tym nasze przekonanie co do prawdziwości H_0 jest mniejsze. Test t -Studenta to nic innego jak pewna zobiektywizowane reguła prostego faktu: jeżeli $\hat{a} = 0$, to duże wartości \hat{a} świadczą przeciw temu. Im większa jest wartość S_a tym nasze przekonanie, że H_0 nie jest prawdziwe jest mniejsze z kolei (im S_a jest większe tym szacujemy wartość \hat{a} mniej dokładnie)

Przyjmujemy z góry pewną wartość, zwaną **poziomem istotności** (zwyczajowo oznaczanym jako α). **Poziom istotności** określa **prawdopodobieństwo** odrzucenia H_0 w sytuacji gdy ona jest prawdziwa. Mówiąc kolokwialnie: otrzymaliśmy przypadkowo dużą wartość statystyki t pomimo tego że faktycznie $\hat{a} = 0$ – coś co się zdarza b. rzadko.

Poziom istotności $\alpha = 0,05$ oznacza że przeciętnie 5 razy na 100 popełnimy błąd odrzucając H_0 z powodu otrzymania dużej wartości t pomimo tego że tak na prawdę $\hat{a} = 0$

Wartość t odpowiadająca przyjętemu poziomowi istotności nosi nazwę **wartości krytycznej**. Wartości krytyczne odczytujemy z tablic.

Zamiast odczytywać **wartość krytyczną** z tablic i porównywać ją z otrzymaną wartością t można podjąć decyzję wykorzystując podaną na wydruku z Gretla **wartość p**. **Wartość p** to największy *poziom istotności* testu dla którego H_0 należy odrzucić. Jeżeli ten poziom jest mniejszy (lub równy) od zwyczajowo przyjmowanego poziomu istotności, np. $\alpha = 0,05$ to H_0 należy odrzucić, w przypadku przeciwnym nie ma podstaw do odrzucenia H_0 .

Powyższe rozumowanie i procedurę należy stosować per-analogia w przypadku innych testów.

W przykładzie: **wartość p** = 7,06e-07 jest oczywiście dużo mniejsze zarówno do $\alpha = 0,05$ jak i $\alpha = 0,01$.

Wniosek: H_0 należy odrzucić (czas istotnie wpływa na kształtowanie się liczb samochodów.)

Istotność zmiennych można także zweryfikować za pomocą testy F (Fishera-Snedecora)

$$H_0 : a_1 = 0$$

$$H_1 : a_1 \neq 0$$

Podobnie jak w przypadku testu t , patrzemy na wartość p , tj **Wartość p dla testu F**, wynosi ona 7,06e-07. Zatem H_0 należy odrzucić (bo 7,06e-07 jest oczywiście dużo mniejsze zarówno do $\alpha = 0,05$ jak i $\alpha = 0,01$.)

W świetle obu testów zmienna t okazała się istotna statystycznie – model nadaje się do praktycznego wykorzystania.

5 Weryfikacja występowania autokorelacji składnika losowego

Test Durбина-Watsona weryfikuje hipotezę o nieistotności autokorelacji pierwszego rzędu składnika losowego:

W ostatnim wierszu okna wyników znajdują się wartości współczynnika autokorelacji (0,740455) oraz wartość statystyki Durбина-Watsona ($d = 0,608220$).

Stawiamy hipotezy:

$$H_0 : \rho_1 = 0$$

$$H_1 : \rho_1 > 0 \text{ jeżeli otrzymana wartość statystyki Durбина-Watsona jest mniejsza od } 2$$

lub

$H_1 : \rho_1 < 0$ jeżeli otrzymana wartość statystyki Durбина-Watsona jest większa/równa od 2.

W naszym przypadku $d < 2$ zatem wybieramy wariant pierwszy. Gdyby $d > 2$, należy zastosować przekształcenie $d' = 4 - d$.

Wartość krytyczną testu odczytujemy z **Narzędzia → Tablice → DW**. Podajemy liczbę obserwacji (11) oraz liczbę zmiennych bez wyrazu wolnego (1). Otrzymujemy dwie wartości: $dL = 0,9273$ oraz $dU = 1,3241$

Reguła testu: jeżeli $d < dL$ to H_0 należy odrzucić. Jeżeli $d > dU$ to nie ma podstaw do odrzucenia H_0 . Jeżeli $dL < d < dU$ to test nie rozstrzyga o występowaniu autokorelacji.

Zatem autokorelacja 0,740455 w istocie okazała się istotna. Występuje autokorelacja składnika losowego.

6 Testowanie normalności rozkładu reszt (test Doornika-Hansena)

H_0 : rozkład reszt jest normalny

H_1 : rozkład reszt nie jest normalny

Testy → test normalności rozkładu reszt

na wykresie szukamy informacji:

Chi-kwadrat(2) = 1,664 [0,4352]

liczba w nawiasach kwadratowych to **wartość p** testu. Ponieważ 0,4352 jest większe zarówno od 0,05 jak i 0,01 zatem nie ma podstaw do odrzucenia H_0 – reszty modelu mają rozkład normalny.

7 Test heteroskedastyczności (White'a)

H_0 : występuje homoskedastyczność reszt składnika losowego (zróznicowanie reszt jest stałe)

H_1 : występuje heteroskedastyczność reszt składnika losowego (zróznicowanie reszt nie jest stałe)

Testy → test heteroskedastyczności → test White'a

Test White'a na heteroskedastyczność reszt (zmiennosc wariacji resztowej)

Estymacja KMNK, wykorzystane obserwacje 1998-2008 (N = 11)

Zmienna zależna (Y): uhat^2

	współczynnik	błąd standardowy	t-Studenta	wartość p
const	3,88746e+11	3,18071e+11	1,222	0,2564
time	-1,60036e+11	1,21824e+11	-1,314	0,2254
sq_time	1,78831e+10	9,88772e+09	1,809	0,1081

Wsp. determ. R-kwadrat = 0,472814

Statystyka testu: $TR^2 = 5,200958$,
z wartością $p = P(\text{Chi-kwadrat}(2) > 5,200958) = 0,074238$

Liczba 0,074238 to **wartość p** testu. Ponieważ 0,074238 jest większe zarówno od 0,05 jak i 0,01 zatem nie ma podstaw do odrzucenia H_0 . Występuje homoskedastyczność reszt składnika losowego (zróznicowanie reszt jest stałe)

8 Ocena liniowości postaci analitycznej modelu

H_0 : relacja liniowa

H_1 : relacja nieliniowa-wielomian drugiego stopnia

Testy → test nieliniowości (kwadraty)

Pomocnicze równanie regresji dla testu nieliniowości (kwadraty zmiennych)
Estymacja KMNK, wykorzystane obserwacje 1998-2008 (N = 11)
Zmienna zależna (Y): uhat

	współczynnik	błąd standardowy	t-Studenta	wartość p	
const	1,29131e+06	312144	4,137	0,0033	***
time	-595988	119554	-4,985	0,0011	***
sq_time	49665,6	9703,46	5,118	0,0009	***

Wsp. determ. R-kwadrat = 0,766064

Statystyka testu: $TR^2 = 8,42671$,
z wartością $p = P(\text{Chi-kwadrat}(1) > 8,42671) = 0,00369749$

liczba 0,00369749 to **wartość p** testu. Ponieważ 0,00369749 jest mniejsze od 0,05 to **na tym poziomie istotności** H_0 należy odrzucić – istnieją podstawy do przyjęcia postaci potęgowej modelu.

Jednakże jeżeli przyjmujemy poziom istotności $\alpha = 0,01$ wtedy decyzja będzie inna: nie ma podstaw do odrzucenia H_0 , tj. hipotezy iż liczba samochodów w badanym okresie jest liniowa.

9 Ekonometryczny model tendencji rozwojowej kwadratowa funkcja trendu

Dodawanie zmiennych → definiowanie nowej zmiennej

wpisać

```
t2 = time * time
```

Model → klasyczna metoda najmniejszych kwadratów

dodać do zmiennych objaśniających (regresory) zmienną t2

Model 3: Estymacja KMNK, wykorzystane obserwacje 1998–2008 (N = 11)
Zmienna zależna (Y): samochody

	współczynnik	błąd standardowy	t-Studenta	wartość p	
const	9,22943e+06	312144	29,57	1,86e-09	***
time	44436,6	119554	0,3717	0,7198	
t2	49665,6	9703,46	5,118	0,0009	***
Średn. aryt. zm. zależnej	11780668	Odch. stand. zm. zależnej	2188115		
Suma kwadratów reszt	6,46e+11	Błąd standardowy reszt	284230,2		
Wsp. determ. R-kwadrat	0,986501	Skorygowany R-kwadrat	0,983127		
F(2, 8)	292,3261	Wartość p dla testu F	3,32e-08		
Logarytm wiarygodności	-151,9898	Kryt. inform. Akaike'a	309,9795		
Kryt. bayes. Schwarza	311,1732	Kryt. Hannana-Quinna	309,2271		
Autokorel. reszt - rho1	0,453759	Stat. Durbina-Watsona	1,030795		

$$y_t = 9229430 + 44436,6 \cdot t + 49665,6 \cdot t^2 + u_t$$

Na podstawie wartości skorygowanego współczynnika determinacji R^2 można stwierdzić, że model (trendu liniowego) w 98,31% objaśnia liczbę zarejestrowanych samochodów. Albo: model (trendu liniowego) w 100% – $R^2 = 1,69$ nie wyjaśnia liczby zarejestrowanych samochodów.

Istotność statystyczną zmiennych:

$$H_o : a_1 = 0, H_1 : a_1 \neq 0$$

$$H_o : a_2 = 0, H_1 : a_2 \neq 0$$

Dla a_1 **wartość p** = 0,7198 jest oczywiście dużo większa zarówno od

$\alpha = 0,05$ jak i $\alpha = 0,01$.

Wniosek: nie ma podstaw do odrzucenia H_0 .

Model nie nadaje się do praktycznego wykorzystania. [Jeżeli otrzymamy taki wynik nie musimy weryfikować hipotez dot. rozkład reszt.]

10 Trend potęgowy/wykładniczy/wielomian stopnia drugiego

Potęgowa

$$y = a_0 \cdot t^{a_1} \cdot u \quad \text{Obustronnie logarytmujemy}$$

$$\ln y = \ln a_0 + a_1 \cdot \ln t + u$$

interpretacja: Z okresu na okres wartość y rośnie/spada o $a_1\%$

Przykład:

Model 3: Estymacja KMNK, wykorzystane obserwacje 1998-2008 (N = 11)
Zmienna zależna (Y): l_samochody

	współczynnik	błąd standardowy	t-Studenta	wartość p	
const	15,9196	0,0597411	266,5	7,51e-19	***
ltime	0,218345	0,0342843	6,369	0,0001	***
Średn.aryt.zm.zależnej	16,26697	Odch.stand.zm.zależnej	0,179838		
Suma kwadratów reszt	0,058732	Błąd standardowy reszt	0,080782		
Wsp. determ. R-kwadrat	0,818402	Skorygowany R-kwadrat	0,798224		
F(1, 9)	40,55993	Wartość p dla testu F	0,000130		
Logarytm wiarygodności	13,17134	Kryt. inform. Akaike'a	-22,34268		
Kryt. bayes. Schwarz	-21,54689	Kryt. Hannana-Quinna	-22,84432		
Autokorel.reszt - rho1	0,703115	Stat. Durbina-Watsona	0,542312		

Na podstawie wartości skorygowanego współczynnika determinacji R^2 można stwierdzić, że model (trendu liniowego) w 79,8% objaśnia liczbę zarejestrowanych samochodów. Albo: model (trendu liniowego) w 100% – $R^2 = 20,2$ nie wyjaśnia liczby zarejestrowanych samochodów.

Istotność statystyczną zmiennych:

$$H_0 : a_1 = 0, H_1 : a_1 \neq 0$$

Dla a_1 **wartość p** = 0,0001 jest oczywiście mniejsza zarówno od $\alpha = 0,05$ jak i $\alpha = 0,01$.

Wniosek: H_0 należy odrzucić.

Dopasowanie modelu jest słabe (niska wartość R^2) ale wartość parametru a_1 jest istotna (czas istotnie wpływa na liczbę samochodów)

Wykładnicza

$$y = a_0 \cdot a_1^t \cdot e^u \quad \text{Obustronnie logarytmujemy}$$

$$\ln y = \ln a_0 + t \cdot \ln a_1 + u$$

interpretacja: Z okresu na okres wartość y rośnie/spada o $(a_1 - 1) \cdot 100\%$

Model 4: Estymacja KMNK, wykorzystane obserwacje 1998–2008 (N = 11)
Zmienna zależna (Y): l_samochody

	współczynnik	błąd standardowy	t-Studenta	wartość p	
const	15,9460	0,0200417	795,6	3,98e-23	***
time	0,0534936	0,00295499	18,10	2,18e-08	***
Średn.aryt.zm.zależnej	16,26697	Odch.stand.zm.zależnej	0,179838		
Suma kwadratów reszt	0,008645	Błąd standardowy reszt	0,030992		
Wsp. determ. R-kwadrat	0,973271	Skorygowany R-kwadrat	0,970301		
F(1, 9)	327,7112	Wartość p dla testu F	2,18e-08		
Logarytm wiarygodności	23,70958	Kryt. inform. Akaike'a	-43,41916		
Kryt. bayes. Schwarza	-42,62336	Kryt. Hannana-Quinna	-43,92079		
Autokorel.reszt - rho1	0,600841	Stat. Durbina-Watsona	0,772287		

$$\ln y_t = \ln \alpha_0 + \ln \alpha_1 \cdot t + u_t \quad (1)$$

Obliczenie α_1 : ponieważ $\ln \alpha_1 = 0,0534936$ zatem (z definicji logarytmu): $\alpha_1 = e^{0,0534936} \approx 1,05$.

Z okresu na okres liczba samochodów rośnie o $(1,05 - 1) \cdot 100\% = 5\%$

Na podstawie wartości skorygowanego współczynnika determinacji R^2 można stwierdzić, że model (trendu liniowego) w 97,0% objaśnia liczbę zarejestrowanych samochodów. Albo: model (trendu liniowego) w 100% – $R^2 = 3,0$ nie wyjaśnia liczby zarejestrowanych samochodów.

Istotność statystyczną zmiennych:

$$H_0 : a_1 = 0, H_1 : a_1 \neq 0$$

Dla a_1 **wartość p** ≈ 0 jest oczywiście mniejsza zarówno od $\alpha = 0,05$ jak i $\alpha = 0,01$.

Wniosek: H_0 należy odrzucić.

Dopasowanie modelu jest bardzo dobre (wysoka wartość R^2 , wyższa o 3,5% niż w przypadku trendu liniowego). Wartość parametru a_1 jest istotna (czas istotnie wpływa na liczbę samochodów).

Wielomian drugiego stopnia (trend kwadratowy):

$$y = a_0 + a_1 \cdot t + a_2 \cdot t^2 + e$$

interpretacja: nie ma

Aby oszacować ww. trendy należy zdefiniować nowe zmienne $\ln y$, $\ln t$ oraz t^2

Dodawanie zmiennych → definiowanie nowej zmiennej

```
lsamochody = logarytm (samochody)
t2 = time * time
```

Oczywiście ocenić dopasowanie modelu, zweryfikować istotność parametrów oraz przetestować rozkład reszt.

11 Model trendu liniowego ze zmiennymi zero-jedynkowymi

Wahania sezonowe reprezentowane są przez zmienne zero-jedynkowe oznaczające poszczególne okresy w cyklu sezonowości (zmiennych musi być $h - 1$, gdzie h jest liczbą okresów, np. dla kwartałów $h = 4$).

Na podstawie danych za lata 2002Q1–2020Q3 oszacowano liniowy model trendu uwzględniający sezonowość z wykorzystaniem zmiennych zero-jedynkowych, Otrzymano

Model 1: Estymacja KMNK, wykorzystane obserwacje 2002:1–2020:3 (N = 75)
Zmienna zależna (Y): PKB

	współczynnik	błąd standardowy	t-Studenta	wartość p	
const	212177	4754,43	44,63	3,68e-53	***
time	5256,67	81,6018	64,42	4,73e-64	***
dq1	−54653,3	5030,05	−10,87	1,13e-16	***
dq2	−46260,9	5029,39	−9,198	1,15e-13	***
dq3	−42540,7	5030,05	−8,457	2,63e-12	***
Średn.aryt.zm.zależnej	375588,8	Odch.stand.zm.zależnej	117566,2		
Suma kwadratów reszt	1,64e+10	Błąd standardowy reszt	15290,70		
Wsp. determ. R-kwadrat	0,983999	Skorygowany R-kwadrat	0,983084		
F(4, 70)	1076,159	Wartość p dla testu F	4,95e-62		
Logarytm wiarygodności	−826,4582	Kryt. inform. Akaike'a	1662,916		
Kryt. bayes. Schwarza	1674,504	Kryt. Hannana-Quinna	1667,543		
Autokorel.reszt - rho1	0,343244	Stat. Durbina-Watsona	1,262010		

Interpretacja: przeciętny roczny wzrost PKB (bez uwzględnienia wahań sezonowych) wynosi 5256,7 mln zł. Współczynników przy zmiennych sq1–dq3 nie interpretuje się (będą miały inną wartość jeżeli zamiast dq1–dq3 wybralibyśmy na przykład dq2–dq4, proszę sprawdzić)

Ocena istotności paramaterów/autokorelacji składnika losowego jak w modelu bez sezonowości...

12 Prognozy

Analiza → Prognoza

Dla 95% przedziału ufności, $t(9, 0,025) = 2,262$

	samochody	prognoza	błąd ex ante	95% przedział ufności
2004	11975191,00	12421092,70		
2005	12339353,00	13061517,04		
2006	13384229,00	13701941,37		
2007	14588739,00	14342365,71		
2008	16079533,00	14982790,05		
2009	16479200,00	15623214,38	659799,206	14130644,88 - 17115783,88
2010	17156400,00	16263638,72	686740,787	14710123,13 - 17817154,31

Miary dokładności prognoz ex post

Średni błąd predykcji	ME =	8,7437e+05
Błąd średniokwadratowy	MSE =	7,6487e+11
Pierwiastek błędu średniokwadr.	RMSE =	8,7457e+05
Średni błąd absolutny	MAE =	8,7437e+05
Średni błąd procentowy	MPE =	5,199
Średni absolutny błąd procentowy	MAPE =	5,199
Współczynnik Theila (w procentach)	I =	1,3183
Udział obciążoności predykc.	$I1^2/I^2$ =	0,99956
Udział niedost. elastyczności	$I2^2/I^2$ =	0,00044205
Udział niezgodności kierunku	$I3^2/I^2$ =	0

Względny błąd prognozy ex-ante: $659799,206/15623214,38 \cdot 100 = 4,2\%$ (w okresie 2009) oraz $686740,787/17156400,00 \cdot 100 = 4,0\%$ (w okresie 2010). Średni absolutny błąd procentowy MAPE = 5,199

W 2009 r. prognozowana liczba samochodów miała wynieść 15623214,38 (wyniosła 16479200,00, różnica 855985 samochodów).

Podobnie można policzyć prognozę dla roku 2010.

Jeżeli oszacowaliśmy dwa modele np. trendu liniowego oraz potęgowego i oba zostały zweryfikowane jako nadające się do praktycznego wykorzystania (dobrze dopasowane, istotne parametry) to należy porównać prognozy otrzymane za pomocą tych modeli.

Na przykład:

Prognoza przy zastosowaniu trendu wykładniczego:

Dla 95% przedziału ufności, $t(9, 0,025) = 2,262$

l_samochody	prognoza	błąd ex ante	95% przedział ufności
-------------	----------	--------------	-----------------------

2004	16,298348	16,320467		
2005	16,328304	16,373961		
2006	16,409588	16,427454		
2007	16,495760	16,480948		
2008	16,593058	16,534441		
2009	16,617610	16,587935	0,036908	16,504444 - 16,671426
2010	16,657882	16,641429	0,038415	16,554528 - 16,728329

Miary dokładności prognoz ex post

Średni błąd predykcji	ME =	0,023064
Błąd średniokwadratowy	MSE =	0,00057564
Pierwiastek błędu średniokwadr.	RMSE =	0,023993
Średni błąd absolutny	MAE =	0,023064
Średni błąd procentowy	MPE =	0,13867
Średni absolutny błąd procentowy	MAPE =	0,13867
Współczynnik Theila (w procentach)	I =	0,40855
Udział obciążoności predykc. $I1^2/I^2$	=	0,92408
Udział niedost. elastyczności $I2^2/I^2$	=	0,075916
Udział niezgodności kierunku $I3^2/I^2$	=	0

Względny błąd prognozy ex-ante: $0,036908/16,58793 \cdot 100 = 2,2\%$ (w okresie 2009) oraz $0,038415/16,64142 \cdot 100 = 2,3\%$ (w okresie 2010). Średni absolutny błąd procentowy MAPE = 0,13.

W 2009 r. prognozowana liczba samochodów miała wynieść $e^{16,587935} = 15997371,73$ („delogarytmujemy”) (wyniosła $e^{16,617610} = 16479200,00$ samochodów, różnica 481828,3 samochodów).

Podobnie można policzyć prognozę dla roku 2010.

Właściwości prognostyczne modelu z trendem wykładniczym są lepsze o czym świadczą niższe wartości błędów prognoz ex-ante oraz ex-post (zastosowano miary względne z uwagi na różne miana zmiennej zależnej w porównywanych modelach).

13 Zadanie do wykonania

Za pomocą programu Gretl

Plik → Otwórz dane → Pliki użytkowników makro_dane_95_08

Powtórzyć obliczenia jak w przykładzie o liczbie samochodów dla jednej wybranej zmiennej (każda grupa wybiera inną zmienną) Opis zmiennych:

Dane z Rachunków Narodowych

CONS spożycie ogółem, RN, mln zł, ceny stałe 1995
CONSI spożycie indywidualne , RN, mln zł, ceny stałe 1995
INW nakłady brutto na środki trwałe, RN, mln zł, ceny stałe 1995
POPKR popyt krajowy, RN, mln zł, ceny stałe 1995
PKB produkt krajowy brutto, RN, mln zł, ceny stałe 1995
GVA wartość dodana brutto, RN, mln zł, ceny stałe 1995
GVAP wartość dodana brutto w przemyśle, RN, mln zł, ceny stałe 1995
GVAB wartosc dodana brutto w budownictwie, RN, mln zł, ceny stałe 1995

CONS cb spożycie ogółem, RN, mln zł, ceny bieżące
CONSI cb spożycie indywidualne , RN, mln zł, ceny bieżące
INW cb nakłady brutto na środki trwałe, RN, mln zł, ceny bieżące
POPKR cb popyt krajowy, RN, mln zł, ceny bieżące
PKB cb produkt krajowy brutto, RN, mln zł, ceny bieżące
GVA cb wartość dodana brutto, RN, mln zł, ceny bieżące
GVAP cb wartość dodana brutto w przemyśle, RN, mln zł, ceny bieżące
GVAB cb wartosc dodana brutto w budownictwie, RN, mln zł, ceny bieżące

Zmienne makroekonomiczne, Biuletyn Statystyczny GUS

ZP przeciętne zatrudnienie w przemyśle, tys. os, Tabl. 11, PS 11.2008, PS 6,2009
ZPP przeciętne zatrudnienie w przemyśle przetwórczym, tys. os, Tabl. 11, BS 11.2008
IPPB indeks produkcji przemysłowej, poprzedni kwartał=100
IPPPB indeks produkcji w przem. przetwórczym, poprz. kwartał =100
CPIB indeks CPI, poprzedni kwartał=100
PPIB indeks cen produkcji przemysłowej, poprzedni kwartał=100,
PPIBPP indeks cen produkcji przemysłowej, poprzedni kwartał=100,
EKSPB indeks eksportu, poprzedni kwartał = 100
WSP przecietne miesieczne wynagrodzenie brutto w sektorze przedsiębiorstw, k.o., pln

Sytuacja finansowa przedsiębiorstw, Biuletyn Statystyczny GUS

ZAPPRZ zapasy w mln pln - przemysł ogółem,, BS Tabl. 32
ZAPPP zapasy w mln pln - przetwórstwo przemysłowe,
NALPRZ należności i roszczenia w mln pln - przemysł ogółem, BA Tabl. 32
NALPP należności i roszczenia w mln pln - przetwórstwo przemysłowe,
WFBP wynik finansowy brutto w mln pln - przemysł razem, Tabl. 29, PS 11.2008
WFBPP wynik finansowy brutto w mln pln - przetwórstwo przemysłowe, Tabl. 29, PS 11.2008

PRZSP przychody ze sprzedaży produktów, towarów i materiałów w mln pln, przemysł razem, T.
PRZSPP przychody ze sprzedaży produktów, towarów i materiałów w mln pln, przetwórstwo prze

Sytuacja gospodarstw domowych, Biuletyn NBP, Biuletyn GUS

KR zadłużenie gospodarstw domowych w sektorze bankowym w Polsce, c.b., mln pln
DEP oszczędności gospodarstw domowych w sektorze bankowym w Polsce, c.b., mln pln
SRD stopa redyskonta weksli, w %
WSP przecietne miesieczne wynagrodzenie brutto w sektorze przedsiębiorstw, k.o., pln
m0r podaż pieniądza, agregat m0, mln pln, wartosc realna
m1r podaż pieniądza, agregat m1, mln pln, wartosc realna
m2r podaż pieniądza, agregat m2, mln pln, wartosc realna
m3r podaż pieniądza, agregat m3, mln pln, wartosc realna
ddbn dochody do dyspozycji brutto, mln pln, wartości nominalne
ddbr dochody do dyspozycji brutto, mln pln, wartości realne